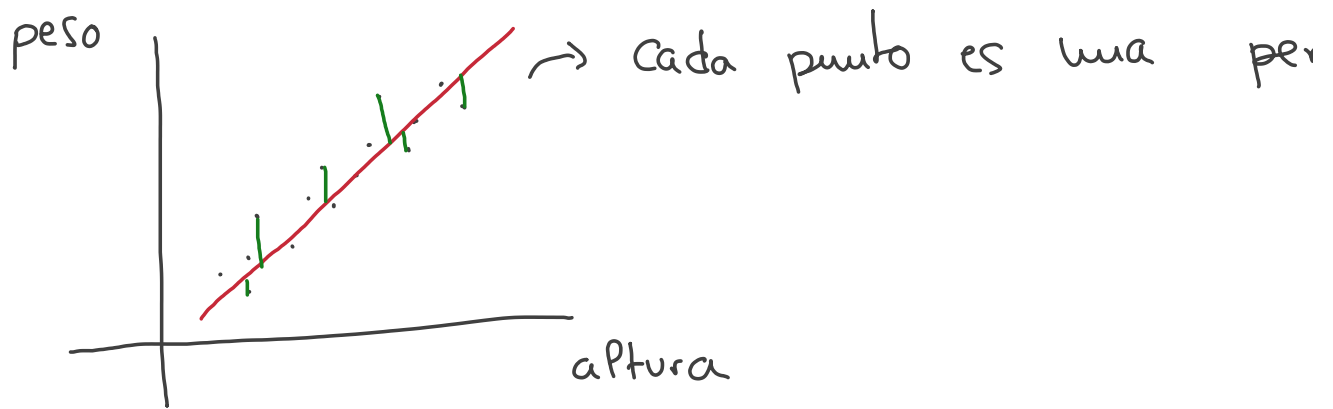


Supongamos que tenemos la siguiente representación de dos variables:



- ¿Existe alguna relación entre las dos variables?
- ¿Se puede encontrar una aproximación lineal a los datos?

La respuesta a las dos preguntas es sí.
La aproximación que vamos a buscar con los datos es una recta (aprox. lineal)

Ecuación de una recta

$$y = a + bx \Rightarrow y = \beta_0 + \beta_1 x$$

Desarrollemos el ejemplo:

Se toma la altura y el peso a
(Ejemplo R)

Resultado :

$$y = -98.23 + 95.24 X$$


↳ Esta sería la recta de aproximación
respecto a la altura

Ahora supongamos que se quiere hacer
físico y algunas personas rellenan el
pero olvidan el peso. Se decide utilizar
lineal antes utilizada:

Competidor 1 \Rightarrow altura = 1.88 \Rightarrow peso = -98.23

Competidor 2 \Rightarrow altura = 1.61 \Rightarrow peso = -98.23 +

Esta recta $y = -98.23 + 95.24 X$



↓
pendiente de la re


B_0 = valor de y a

B_1 = pendiente de

Otro ejemplo:

y = nota de la materia AED

x = horas de estudio a la semana



→ De nuevo correlación
A más horas de estudio
más nota 😊

En este caso obtenemos $\text{nota} = 1.78$

¿Cómo se interpretan los β_i 's?

β_0 = la nota obtenida en el caso de que estudio sean 0.

β_1 = cuanto aumentará y (nota) en caso aumente 1 unidad.

↳ es decir, a cada hora extra aumenta 0.79 la nota de AED.

Ejemplo regresión negativa: Temperatura

Ahora bien, esto es mucho más útil cuando con más de 2 variables.

Supongamos que queremos predecir 1 partir de otras. El concepto es el mismo

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots$$

↓
variable
respuesta

↓ ↓
variables
predictoras

Por ejemplo:

$$Y = \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \dots$$

↓
valor
propiedad
inmobiliaria


↓ ↓ ↓
zona m² antigüedad

Cuanta más información añadamos en mejor ajustará.

Modelo final:

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_r X_r + \underline{\varepsilon} \rightarrow \text{error!}$$

Para ajustar lo mejor posible este modelo
minimizar los errores.



2 dimensiones

Error: Diferencia entre valor real y

Objetivo: Minimizar la suma de todos

Por tanto: Buscamos los β_i 's del
que la recta sea óptima, es decir, que
los errores.

Un poco de teoría:

Sea el modelo de regresión lineal:

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_r X_r + \epsilon$$

Si hay n observaciones independientes
expandirlo como:

$$y_i = \beta_0 + \beta_1 \cdot x_{i1} + \dots + \beta_r x_{ir} + \underbrace{\epsilon_i}_{\text{obs. 1 var. r}}$$

$$y_1 = \beta_0 + \beta_1 x_{11} + \dots + \beta_r x_{1r}$$

$$y_2 = \beta_0 + \beta_1 x_{21} + \dots + \beta_r x_{2r} + \varepsilon_2$$

\vdots

$$y_n = \beta_0 + \beta_1 x_{n1} + \dots + \beta_r x_{nr} + \varepsilon_n$$

Estos errores son una variable aleatoria
se asume que:

$$1) E(\varepsilon_i) = 0 \Rightarrow E(y_i) = \beta_0 + \beta_1 x_{i1}$$

$$2) \text{Var}(\varepsilon_i) = \sigma^2 \text{ (cte)}$$

$$3) \text{Cov}(\varepsilon_i, \varepsilon_j) = 0 \quad \forall i \neq j \text{ (Indeps)}$$

Esto lo veremos más adelante.

Podemos escribir en notación matricial:

$$\begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & \dots & x_{1r} \\ \vdots & \ddots & & \vdots \\ 1 & x_{n1} & \dots & x_{nr} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_r \end{pmatrix} +$$

$$\Rightarrow Y = X \cdot \beta + \varepsilon$$

donde cada col. de X son las n

var. predictor as y cada t i de
valores de las var. predictor as en

Estimador de mínimos cuadrados

Vamos a estudiar cómo se calculan
manera que devuelva los valores más
con relación lineal de Y y X .

Es decir, los β_i 's que minimicen los
residuos) $\Rightarrow \beta_i$'s que minimicen la diferencia
el valor real y el valor estimado.

Por tanto, intentamos minimizar la
cuadrados:

$$S(\mathbf{b}) = \sum_{i=1}^n \underbrace{(y_i - b_0 - b_1 x_{i1} - \dots - b_r x_{ir})}_{\text{real} - \text{estimado}}^2$$
$$= (Y - \mathbf{b}X)' (Y - \mathbf{b}X)$$

Definición: Las entradas de \mathbf{b} que mi
se obtienen con mínimos cuadrados y

denotamos $\hat{\beta}$.

Teorema: El estimador de mínimos cuadrados está dado por:

$$\hat{\beta} = (X'X)^{-1} X'y$$

estimados

Además, los residuos \downarrow se pueden calcular

$$\hat{\epsilon} = y - \hat{y} = y - Hy$$

con $H = X(X'X)^{-1}X'$

Ejemplo:

Example 7.3 (Calculating the least squares estimates, the residuals, and the residual sum of squares)

Calculate the least square estimates $\hat{\beta}$, the residuals $\hat{\epsilon}$, and the residual sum of squares for a straight-line model

$$Y_j = \beta_0 + \beta_1 x_{j1} + \epsilon_j$$

fit to the data

x_1	0	1	2	3	4
y	1	4	3	8	9


We have

Z'	y	$Z'Z$	$(Z'Z)^{-1}$	$Z'y$
$\begin{matrix} 1's \rightarrow \\ x_1 \rightarrow \end{matrix} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 0 & 1 & 2 & 3 & 4 \end{bmatrix}$	$\begin{bmatrix} 1 \\ 4 \\ 3 \\ 8 \\ 9 \end{bmatrix}$	$\begin{bmatrix} 5 & 10 \\ 10 & 30 \end{bmatrix}$	$\begin{bmatrix} .6 & -.2 \\ -.2 & .1 \end{bmatrix}$	$\begin{bmatrix} 25 \\ 70 \end{bmatrix}$

10+



Consequently



reales

estimados

Consequently,

$$\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix} = (\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{y} = \begin{bmatrix} .6 & -.2 \\ -.2 & .1 \end{bmatrix} \begin{bmatrix} 25 \\ 70 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

and the fitted equation is

$$\hat{y} = 1 + 2z \rightarrow \text{Recta de reg}$$

The vector of fitted (predicted) values is

$$\text{est} \rightarrow \hat{\mathbf{y}} = \mathbf{Z}\hat{\beta} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 \\ 3 \\ 5 \\ 7 \\ 9 \end{bmatrix}$$

so

$$\hat{\epsilon} = \mathbf{y} - \hat{\mathbf{y}} = \begin{bmatrix} 1 \\ 4 \\ 3 \\ 8 \\ 9 \end{bmatrix} - \begin{bmatrix} 1 \\ 3 \\ 5 \\ 7 \\ 9 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ -2 \\ 1 \\ 0 \end{bmatrix}$$

The residual sum of squares is

$$\hat{\epsilon}'\hat{\epsilon} = \begin{bmatrix} 0 & 1 & -2 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \\ -2 \\ 1 \\ 0 \end{bmatrix} = 0^2 + 1^2 + (-2)^2 + 1^2 + 0^2 = 6 \quad \blacksquare$$